


Оценка стоимости автомобилей: Разработка ML-модели

Построение быстрой и точной системы предсказания цен для сервиса «Не бит, не крашен»



Бизнес-задача

Приложению «Не бит, не крашен» требуется функция мгновенной оценки рыночной стоимости автомобиля по его характеристикам. Модель должна работать в режиме реального времени и быть устойчивой к частым обновлениям данных.



Качество (Точность)

RMSE < 2500 евро

Скорость ответа



Мгновенное
предсказание

Обучаемость



Быстрое
переобучение

Паспорт исходных данных

354 369


Записей в базе

16

Исходных признаков


Красные флаги диагностики

Статус ремонта (repaired)




20.08% пропусков

Тип кузова (vehicle_type)



10.58% пропусков


Тип топлива (fuel_type)



9.28% пропусков

Вывод: Выявлены критические аномалии — нулевая мощность двигателей ($\text{power} = 0$) и нереалистичные годы регистрации. Данные требуют глубокой инженерии перед подачей в алгоритмы.


Портрет типичного автомобиля



Инсайт: Самые популярные машины в выборке — это бензиновые седаны и малолитражки на механике, которые никогда не были в ремонте.

Распределение рынка (Numerical Insights)

Стоимость (Price)




Основная масса машин стоит до **2500** евро.

Год выпуска (Registration Year)




Пик регистраций приходится на **2000–2005** годы.

Мощность (Power)



Абсолютное большинство имеет мощность до **200 л.с.**

Пробег (Kilometer)




Экстремальный сдвиг вправо — большинство машин имеют пробег **>120 000 км.**

Радар влияния (Influence Map)



Вывод: Возраст и мощность двигателя — фундаментальные драйверы стоимости в нашей модели. Остальные факторы служат корректирующими **коэффициентами**.

Воронка очистки (Data Purification Funnel)



Подготовка к ML: Разделение потоков (Feature Engineering)

Очищенный датасет

Поток 1: Для Линейной Регрессии

Масштабирование численных данных
(StandardScaler)

Прямое кодирование категорий
(One-Hot Encoding)

Устранение мультиколлинеарности
(удален признак 'model')

Обучающая выборка (Train)

Тестовая выборка (Test)

Поток 2: Для Градиентного Бустинга (LightGBM & CatBoost)

Прямая подача сырых
категориальных признаков

Использование внутренних
механизмов алгоритмов.
Экономия памяти и времени.

Обучающая выборка (Train)

Тестовая выборка (Test)

Участники тестирования

Линейная регрессия

Baseline

Базовый уровень. Простая и интерпретируемая модель. Необходима для проверки на адекватность (Sanity Check) более сложных архитектур.

LightGBM

Скоростной бустинг

Алгоритм от Microsoft. Разработан для легкости и невероятной скорости обучения на больших объемах данных.

CatBoost

Категориальный тяжеловес

Мощная архитектура от Yandex. Идеально и без лишней предобработки работает с сырыми категориальными текстами из коробки.


Методология судейства: Поиск оптимальных гиперпараметров проводился через RandomizedSearchCV (баланс между глубиной поиска и временем).

Главная матрица сравнения

Модель	Качество (RMSE)	Время обучения	Время предсказания
Линейная Регрессия	2542.85 (KPI не пройден)	12.29 сек.	—
LightGBM	1662.34	10.50 сек.	1.25 сек.
CatBoost	1690.97	9.27 сек.	0.18 сек.

Требование бизнеса: RMSE строго меньше 2500.

Почему побеждает CatBoost?



1. Точность с запасом

RMSE 1690 блестяще проходит бизнес-порог (<2500). Незначительное отставание от LightGBM полностью компенсируется скоростью.




2. Безоговорочное лидерство в скорости

CatBoost быстрее обучается и делает предсказания почти в 7 раз быстрее конкурента.



3. Архитектурная элегантность

Удобство работы с категориальными фичами из коробки, без раздувания матриц через ONE, делает pipeline более стабильным и компактным.



Стабильный Pipeline

Валидация на тестовой выборке

PRODUCTION
APPROVED

Надежность
(Test Set RMSE)

1693.38 ↑

Падение качества минимально. Модель стабильна и не имеет признаков переобучения на новых данных.

Пользовательский опыт
(Время ответа)

0.136 сек. ⌚

В интерфейсе приложения клиент получит расчет стоимости своего автомобиля мгновенно.

Итоги проекта и Рекомендации

Чек-лист проекта



Исторические данные сервиса «Не бит, не крашен» очищены от критических аномалий и структурных дубликатов.



Протестированы 3 ML-архитектуры. Выявлен оптимальный набор гиперпараметров.



Выполнено жесткое бизнес-требование: ошибка предсказания снижена до **~1690 евро** (при норме 2500).

Бизнес-решение

Рекомендуется интеграция модели **CatBoost в продакшен**. Она обеспечивает идеальный баланс: высокая точность оценки рыночной стоимости и феноменально быстрый отклик (0.13с), что критично для удержания внимания пользователей мобильного приложения.